



Calcul Scientifique et Optimisation CSOPT

TP1: Optimisation sans et avec contraintes

Année scolaire: 2024-2025

Students:

FARACH Mohamad-Hamza

ABDALLAH Dina

ZAHRAMAN Abbas

Contents

1	Minimisation de la fonction de Rosenbrock	5
1.1	Travail préliminaire	5
1.2	Visualisation de la fonction objectif	6
1.3	Minimisation par descente itérative	7
1.3.1	Méthode de descente de plus forte pente avec un pas fixe	7
1.3.2	Méthode de descente de plus forte pente avec un pas variable (condition d'Armijo)	10
1.3.3	Comparaison des performances des algorithmes d'optimisation par descente itérative	10
1.3.4	Comparaison des performances des méthodes de Gauss-Newton et Levenberg-Marquardt	13
2	Ajustement d'une courbe non linéaire	14
2.1	Travail préliminaire	14
2.2	Visualisation de la fonction objectif	15
2.3	Résolution du problème par différentes méthodes itératives	15
3	Conclusion	17

List of Figures

1	allure de f_0 sur $[-4, 4] \times [-5, 20]$	7
2	lignes de niveaux (100) de f_0	7
3	Evolution de la norme du gradient de f_0 au cours des itérations avec f_0 . . .	8
4	Evolution des itérées sur f_0 pour un pas de 10^{-2}	9
5	Evolution de la norme du gradient de f_0 au cours des itérations avec f_0 pour un pas de 10^{-2}	9
6	Evolution des itérées sur f_0 pour un pas de 10^{-4}	9
7	Evolution de la norme du gradient de f_0 au cours des itérations avec f_0 pour un pas de 10^{-4}	9
8	Evolution des itérées sur f_0 pour un pas de départ de 2	10
9	Evolution de la norme du gradient de f_0 au cours des itérations pour un pas de départ de 2	10
10	Evolution de la norme du gradient de f_0 au cours des itérations	11
11	Evolution du critère f_0 au cours des itérations	11
12	Evolution de la norme du gradient de f_0 au cours des itérations	12
13	Evolution du critère f_0 au cours des itérations	12
14	Evolution de la norme du gradient de f_0 au cours des itérations	13
15	Evolution du critère f_0 au cours des itérations	13
16	Les courbes de niveaux de $\log(f_0)$	15
17	Evolution de la norme du gradient en fonction des itérations pour différentes méthodes itératives.	15
18	Evolution de la fonction objectif en fonction des itérations pour différentes méthodes itératives.	16
19	Comparaison des valeurs du relevé expérimental à celles obtenues par les différentes méthodes itératives.	17

List of Tables

1	Tableau avantage/limite de chaque méthode pour $x_0 = (-4, 10)$	11
2	Tableau avantage/limite de chaque méthode pour $x_0 = (15, 3)$	12
3	Tableau avantage/limite de chaque méthode pour $x_0 = (-4, 10)$	13
4	Résultats obtenus pour les différentes méthodes itératives pour $x_0 = (1,3)$.	16

Introduction

Ces travaux pratiques consistent en la mise en oeuvre de quelques methodes d'optimisation par descente itérative avec recherche lineaire. L'objectif est de réaliser une analyse comparative de ces méthodes à travers 2 exemples classiques : la minimisation de la fonction de Rosenbrock et l'ajustement d'une courbe non-lineaire.

Dans tout le document, f_0 indiquera la fonction objectif qu'on cherche à minimiser et x_0 sera le point initial des différents algorithmes de descente.

1 Minimisation de la fonction de Rosenbrock

1.1 Travail préliminaire

La fonction de Rosenbrock est donnée par :

$$f_0(x) = \sum_{i=1}^{n-1} b \cdot (X_{i+1} - X_i^2)^2 + (1 - X_i)^2$$

Le gradient de la fonction est :

$$\nabla f_0(x) = \begin{cases} -4bX_i(X_{i+1} - X_i^2) - 2(1 - X_i), & \text{pour } i = 1, \dots, n-1 \\ 2b(X_i - X_{i-1}^2), & \text{pour } i = 2, \dots, n \end{cases}$$

Le Hessien de la fonction est :

$$H(x) = \begin{pmatrix} \ddots & & 2b & & 0 & \dots \\ 2b & -4b \cdot (X_{i+1} - 3X_i^2) + 2 & 2b & \dots & & \\ 0 & 2b & & \ddots & 0 & \\ & & & & \ddots & \end{pmatrix}$$

On reformule la fonction $f_0(x)$ sous forme de critère de moindres carrés non linéaires :

$$f_0(x) = \sum_{i=1}^{n-1} (r_{2i-1}(x)^2 + r_{2i}(x)^2)$$

où les résidus $r_j(x)$ sont définis comme suit :

$$\begin{aligned} r_{2i-1}(x) &= \sqrt{b} \cdot (X_{i+1} - X_i^2) \\ r_{2i}(x) &= 1 - X_i \end{aligned}$$

Le Jacobien des résidus est :

$$J(x) = \begin{pmatrix} -2\sqrt{b}X_1 & \sqrt{b} & 0 & \dots & 0 \\ -1 & 0 & \dots & \dots & 0 \\ 0 & -2\sqrt{b}X_2 & \sqrt{b} & \dots & 0 \\ 0 & -1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & -2\sqrt{b}X_{n-1} & \sqrt{b} \\ 0 & 0 & \dots & -1 & 0 \end{pmatrix}$$



Comme cette fonction elle est convexe et coercive alors admet un minimiseur global, ce dernier est atteint lorsque $X_i = 1$ pour tout i , et la valeur de la fonction en ce point optimal est égale à 0.

1.2 Visualisation de la fonction objectif

On prend $n = 2$ et $b = 2$. La fonction de Rosenbrock s'écrit donc:

$$f(x_1, x_2) = 2 \cdot (x_2 - x_1^2)^2 + (1 - x_1)^2 \quad (1)$$

On fait un tracé 3D de la fonction objectif f_0 dans l'intervalle $x_1 \in [-4, 4]$ et $x_2 \in [-5, 20]$.

Figure 1: allure de f_0 sur $[-4, 4] \times [-5, 20]$ Figure 2: lignes de niveaux (100) de f_0

Il est clair que le minimum de la fonction de Rosenbrock f_0 se situe au fond de la vallée (forme de banane) visible sur les figures 1 et 2. En effet, f_0 prend ses valeurs minimales lorsque la couleur du tracé est bleu foncé.

NB : Cette fonction est aussi connue sous le nom de fonction banane (bien visible sur la figure 2).

1.3 Minimisation par descente itérative

1.3.1 Méthode de descente de plus forte pente avec un pas fixe

On prend $x_0 = (2, 4)$.

La méthode de descente de plus forte pente est caractérisée par une direction de descente d :

$$d = -\nabla f_0 \quad (2)$$

Pour un pas $\alpha = 1$:

Avec un pas de 1, la méthode diverge. En effet, l'algorithme renvoie un point final x_h :

$$x_h = (-1.5197 \cdot 10^{231}; 1.3218 \cdot 10^{154})$$

Alors que la valeur de convergence attendue est (1,1). Cette divergence s'observe sur la figure 3, le gradient diverge fortement (tend vers l'infini) au bout de 6 itérations.




Figure 3: Evolution de la norme du gradient de f_0 au cours des itérations avec f_0

Ainsi, à chaque itération, les sauts sont trop grand et le minimum a été raté/sauté. α est donc trop grand.

Pour un pas $\alpha = 10^{-2}$:

Ici, en réduisant le pas, la méthode converge bien vers (1.1172, 1.2703) qui a une valeur proche de (1,1). Cependant, elle n'atteint pas (1,1) car le nombre d'itérations, qui est de 1000, n'est pas assez grand.




Figure 4: Evolution des itérées sur f_0 pour un pas de 10^{-2}




Figure 5: Evolution de la norme du gradient de f_0 au cours des itérations avec f_0 pour un pas de 10^{-2}

La figure 4 montre bien que l'algorithme converge et se dirige vers le minimum. La figure 5 montre, quant à elle, que le nombre d'itérations (1000) a été atteint. De plus, le gradient n'a pas encore atteint la valeur nulle ce qui démontre que le minimum de f_0 n'est pas atteint.

Pour un pas $\alpha = 10^{-4}$:




Figure 6: Evolution des itérées sur f_0 pour un pas de 10^{-4}




Figure 7: Evolution de la norme du gradient de f_0 au cours des itérations avec f_0 pour un pas de 10^{-4}

Ici, le pas α est beaucoup trop faible. L'algorithme converge vers (1.9610, 3.9606). En effet, le nombre maximal d'itérations est atteint très rapidement et les sauts, à chaque itération, sont trop faible. Ainsi, les itérées sont trop proches les unes des autres et l'algorithme n'avance presque pas (trop lent). La figure 6 illustre bien cet aspect. De même, la figure 7 montre, qu'à partir de l'itération 200, le gradient est quasi-constant, i.e, on n'avance pas.

Ainsi, il faudrait un très grand nombre d'itérations (peut être difficile pour l'ordinateur) pour arriver à la valeur recherchée. Il faut donc adapter le pas en fonction de la zone où l'on se trouve pour optimiser le temps de calcul.

1.3.2 Méthode de descente de plus forte pente avec un pas variable (condition d'Armijo)

On intègre, dans l'algorithme, une recherche de pas par une technique de rebroussement (avec un taux $\beta = 0.75$) et une constante $c = 104$ qui vérifie la condition d'Armijo :

$$\phi(\alpha) = f_0(x_k + \alpha_k \cdot d_k) - f_0(x_k) \leq c \cdot \alpha_k \cdot g_k^T \cdot d_k \text{ où } g_k = -\nabla f_0(x_k)$$

On donne un pas de départ, pour la première itération, qui sera ajusté, à chaque itération, de manière à optimiser le saut.




Figure 8: Evolution des itérées sur f_0 pour un pas de départ de 2




Figure 9: Evolution de la norme du gradient de f_0 au cours des itérations pour un pas de départ de 2

Peu importe le pas de départ choisi (raisonnable ≤ 3), l'algorithme converge, de manière quasi-exacte, vers (1,1). Par exemple, avec un pas de départ de 2, sur la figure 8, la convergence vers le point souhaité est bien visible. La figure 9 illustre, aussi, l'efficacité de la condition d'Armijo car le gradient tend très rapidement vers 0 (à partir de 200 itérations).

NB : On voit que l'algorithme de descente de plus forte pente n'est pas le plus précis (demande plus que 1000 itérations) car les valeurs de convergence atteintes ne sont pas exactement égales à (1,1). Dans l'exemple illustré, la valeur à convergence est (1.0202, 1.0450).

1.3.3 Comparaison des performances des algorithmes d'optimisation par descente itérative

La comparaison se porte sur les méthodes suivantes : Gradient, Gradient Conjugué non-linéaire (conjugaison de type Fletcher-Reeves), Newton (pas unitaire), Newton (pas variable), Quasi-Newton de type BFGS.

Pour $x_0 = (-4, 10)$:

Toutes les méthodes ne convergent pas vers la bonne valeur (1, 1). En effet, sur la figure 10, les méthodes du 1er ordre (Gradient et Gradient Conjugué) présentent un gradient qui stationne à une valeur non nulle au bout d'une centaine d'itérations. Ainsi, avec ces méthodes, l'algorithme n'atteint pas un minimum ($\nabla f \neq 0$).

Qui plus est, la figure 11 montre aussi que le fonction objectif f_0 n'atteint pas sa valeur minimale de 0 pour les méthodes du 1er ordre.

Ainsi, pour ce point $x_0 = (-4, 10)$, les méthodes du second ordre sont plus efficaces que celles du 1er ordre puisqu'elles permettent de converger vers la valeur attendue (1, 1) alors que celles du 1er ordre ne sont pas satisfaisantes.




Figure 10: Evolution de la norme du gradient de f_0 au cours des itérations




Figure 11: Evolution du critère f_0 au cours des itérations

Méthode	nombre d'itérations	temps de calcul	point final	arrêt
Gradient	1000	1.3337	(-3.50, 12.57)	Maxiter
Gradient conjugué	1000	1.7750	(-2.48, 6.55)	Maxiter
Newton (pas unitaire)	6	1.4611	(1,1)	TolG
Newton (pas variable)	286	1.3117	(1.00, 1.00)	TolG
Quasi-Newton	310	1.6219	(1.00, 1.00)	TolG

Table 1: Tableau avantage/limite de chaque méthode pour $x_0 = (-4, 10)$

Quant aux méthodes du second ordre, les figures 10 et 11 montrent que les méthodes de Newton (pas variable) et de Quasi-Newton se comportent de manière similaire.

Cependant, la Table 1 révèle, que pour le point $x_0 = (-4, 10)$, la méthode Newton (pas variable) nécessite moins d'itérations (donc moins de calculs) et un temps de calcul plus faible que la méthode de Quasi-Newton. La méthode Newton (pas variable) apparaît donc plus efficace dans ce cas là.

Enfin, la méthode de Nwton (pas unitaire) converge en 6 itérations mais présente un temps de calcul plus élevé que celle de Newton (pas variable).

Par conséquent, le pas unitaire demeure moins efficace même si, dans ce cas précis, la différence est négligeable.

NB : *Le gradient ne converge pas exactement vers 0 mais vers des valeurs très proche de 0 (10e-6 par exemple) car l'ordinateur effectue des calculs numériques non exacts. C'est pourquoi on utilise des conditions de seuil d'arrêt tels que 'TolG' ou 'TolF'.*

Pour $x_0 = (15, 3)$:




Figure 12: Evolution de la norme du gradient de f_0 au cours des itérations




Figure 13: Evolution du critère f_0 au cours des itérations

Les figures 12 et 13 montrent qu'aucune des méthodes ne convergent vers le minimum sauf la méthode de Newton (pas unitaire). Dans ce cas ci, cette méthode se révèle très efficace puisqu'elle continue à converger vers le minimum.

Cependant, les méthodes de Newton (pas variable) et de Quasi-Newton ne convergent pas vers $(1, 1)$.

Méthode	nombre d'itérations	temps de calcul	point final	arrêt
Gradient	1000	1.7149	$(-44.21, 94.14)$	Maxiter
Gradient conjuge	1000	1.5176	$(426.69, -10.76)$	Maxiter
Newton (pas unitaire)	6	0.9864	$(1, 1)$	TolG
Newton (pas variable)	1000	1.4584	$(-1.17e+3, 1.38e+6)$	Maxiter
Quasi-Newton	136	1.7434	$(-2.398e+3, 5.75e+6)$	TolF

Table 2: Tableau avantage/limite de chaque méthode pour $x_0 = (15, 3)$

Pour la méthode de Newton (pas variable) le gradient stationne autour de 10^6 (qui ne représente pas un point stationnaire). La table 2 montre que c'est le 'Maxiter' qui a stoppé l'algorithme. Ainsi, peu importe le nombre de d'itération, la méthode ne convergerait pas vers le minimum.

Pour la méthode Quasi-Newton, c'est la condition 'TolF' qui a arrêté l'algorithme. En conséquence, la variation relative de la norme des itérées était beaucoup trop faible. Il se peut que, si l'on retirait cette condition 'TolF', la méthode convergerait vers $(1, 1)$ avec un très grand nombre d'itérations (trop trop grand/boucle infinie ??).

Ainsi, les méthodes peuvent avoir des trajectoires et résultats différents selon le point initial x_0 choisi.

1.3.4 Comparaison des performances des méthodes de Gauss-Newton et Levenberg-Marquardt

On prend un point initial $x_0 = (-4, 10)$.

Pour les 2 méthodes, comme attendu car étant quasi-quadratiques, l'algorithme converge vers la bonne valeur $(1, 1)$. Ici, sur les figures 14 et 15, $\lambda = 1$ pour la méthode de Levenberg-Marquardt.




Figure 14: Evolution de la norme du gradient de f_0 au cours des itérations




Figure 15: Evolution du critère f_0 au cours des itérations

Méthode	nombre d'itérations	temps de calcul	point final	arrêt
Gauss-Newton	103	1.0817	$(1, 1)$	TolF
Levenberg-Marquardt	999	3.4641	$(1, 1)$	TolF

Table 3: Tableau avantage/limite de chaque méthode pour $x_0 = (-4, 10)$

On voit, sur les figures 14 et 15, que la méthode de Gauss-Newton converge beaucoup plus rapidement et atteint une valeur de gradient nul au bout d'un nombre faible d'itération

par rapport aux autres méthodes étudiées (hormis la méthode de Newton (pas unitaire)) ce qui est cohérent avec le caractère quasi-quadratique.

Cependant, la méthode de Levenberg-Marquardt demande beaucoup plus d'itérations. Cela dépend grandement du choix de λ .

Pour la méthode de Levenberg-Marquardt, le choix de λ va influencer sur la convergence de l'algorithme.

En effet, λ est un paramètre permettant d'ajuster le compromis entre une direction de plus forte pente (λ très grand) et une direction de Gauss-Newton ($\lambda = 0$)

Pour ce x_0 précis, on peut dire que λ est optimal lorsqu'il est proche de 0 (Gauss-Newton)

2 Ajustement d'une courbe non linéaire

2.1 Travail préliminaire

La résistance d'un capteur résistif de mesure d'intensité lumineuse est donnée par:

$R(E) = \beta E^{-\alpha}$. Afin de déterminer les coefficients α et β , on cherche à minimiser la fonction:

$$f_0(\alpha, \beta) = \frac{1}{2} \sum_{i=1}^N (R_i - \beta E_i^{-\alpha})^2 \quad (3)$$

où E_i et R_i sont les relevés expérimentaux obtenus.

Pour trouver le vecteur gradient et la matrice Hessienne on écrit notre fonction sous la forme:

$$f_0(\alpha, \beta) = \frac{1}{2} \sum_{i=1}^N (R_i - \beta e^{-\alpha \ln E_i})^2$$

On trouve: Le vecteur gradient de la fonction:

$$\nabla f_0(\alpha, \beta) = \begin{pmatrix} \sum_{i=1}^N \beta \ln E_i (R_i - \beta E_i^{-\alpha}) E_i^{-\alpha} \\ - \sum_{i=1}^N E_i^{-\alpha} (R_i - \beta E_i^{-\alpha}) \end{pmatrix}$$

et sa matrice Hessienne:

$$H(f_0) = \begin{pmatrix} \sum_{i=1}^N \beta \ln^2 E_i E_i^{-\alpha} (-R_i + 2\beta E_i^{-\alpha}) & \sum_{i=1}^N \ln E_i E_i^{-\alpha} (R_i - 2\beta E_i^{-\alpha}) \\ \sum_{i=1}^N \ln E_i E_i^{-\alpha} (R_i - 2\beta E_i^{-\alpha}) & \sum_{i=1}^N E_i^{-2\alpha} \end{pmatrix}$$

2.2 Visualisation de la fonction objectif

On trace les courbes de niveaux du log-critère $\log(f_0)$ pour $\alpha \in [0, 2]$, $\beta \in [0, 4]$, avec un pas de 0.01




Figure 16: Les courbes de niveaux de $\log(f_0)$.

2.3 Résolution du problème par différentes méthodes itératives

Dans la figure ci-dessous on montre l'évolution de la norme du gradient pour les différentes méthodes itératives discutées précédemment. Notons que pour les valeurs à pas fixe on a pris $\alpha = 0.1$.




Figure 17: Evolution de la norme du gradient en fonction des itérations pour différentes méthodes itératives.

Dans la figure ci-dessous, on montre l'évolution de notre fonction objectif au cours des itérations en adoptant les différentes méthodes.




Figure 18: Evolution de la fonction objectif en fonction des itérations pour différentes méthodes itératives.

En prenant un pas initial égal à 0.1 pour toutes les méthodes mises en jeu, on observe que pour les méthodes d'ordre 1 (la méthode du gradient et du gradient conjugué) la valeur de la fonction f n'est pas suffisamment petite, alors qu'elle converge vers une valeur proche de 0 pour les méthodes d'ordre 2.

Donc, les méthodes d'ordre 1 n'arrive pas à déterminer les valeurs de α et β qui minimisent la fonction objectif. Dans le tableau suivant on récapitule les résultats obtenus pour les différentes méthodes:

Méthode	nombre d'itérations	temps de calcul	point final	arrêt
Gradient	1000	2.1614	(-0.0431, 5.3012)	Maxiter
Gradient conjugué	1000	5.3175	(0.1426, 11.6839)	Maxiter
Newton (pas unitaire)	202	2.7219	(1.1477, 2550.7)	TolX
Newton (pas variable)	202	2.0697	(1.1477, 2550.7)	TolX
Quasi-Newton	206	1.832	(1.1477, 2550.7)	TolX

Table 4: Résultats obtenus pour les différentes méthodes itératives pour $x_0 = (1, 3)$

Pour évaluer les résultats obtenus pour les paramètres de notre modèle, nous avons tracé la variation de R en fonction de E à partir des valeurs expérimentales ainsi que des modèles obtenus en utilisant différentes méthodes. Les résultats sont présentés dans la figure ci-dessous.




Figure 19: Comparaison des valeurs du relevé expérimental à celles obtenues par les différentes méthodes itératives.

Conformément aux résultats obtenus précédemment, on observe que les valeurs des paramètres α et β obtenues par les méthodes d'ordre 1 n'arrivent pas à représenter le modèle en question. Ces méthodes sont linéaires et nécessitent un grand nombre d'itérations pour converger vers la bonne solution. Alors qu'on remarque qu'avec les méthodes de Newton, plutôt quadratiques, la solution est obtenue plus rapidement et on arrive à estimer les paramètres qui modélisent la résistance en fonction de l'intensité lumineuse.

3 Conclusion

Ce rapport a permis d'explorer plusieurs méthodes d'optimisation itérative, en se concentrant sur la minimisation de la fonction de Rosenbrock et l'ajustement de courbes non linéaires. Nous avons comparé les approches de descente par gradient à pas fixe et variable, ainsi que les méthodes de Newton et quasi-Newton. Les résultats montrent que le choix du pas est crucial pour la convergence : un pas trop grand entraîne une divergence, tandis qu'un pas trop petit ralentit l'optimisation. L'utilisation d'un pas variable, comme avec la condition d'Armijo, améliore notablement la stabilité.

Les méthodes de Newton et quasi-Newton, bien que plus coûteuses en termes de calcul, ont démontré une meilleure performance en termes de rapidité et de précision. Les méthodes de gradient, bien que plus simples, nécessitent davantage d'itérations pour converger. En conclusion, pour des problèmes complexes comme la fonction de Rosenbrock, les méthodes de Newton sont préférables, tandis que les méthodes plus simples peuvent suffire pour des problèmes bien conditionnés.